

BÜYÜK VERİ ANALİZİNE GİRİŞ DÖNEM PROJESİ

Teknik Rapor

İLKAY ÇOBAN
KOCAELİ ÜNİVERSİTESİ
210202092

IRMAK YÜCEAK
KOCAELİ ÜNİVERSİTESİ
210202038

BUSENUR HELVACI
KOCAELİ ÜNİVERSİTESİ
220202035

Ders: BÜYÜK VERİ ANALİZİNE GİRİŞ

Özet

Bu projede MovieLens 25M veri seti kullanılarak uçtan uca bir büyük veri pipeline mimarisi geliştirilmiştir. Projede Docker ile konteynerize edilmiş ortam kurulmuş, Apache Kafka ile streaming veri üretimi simüle edilmiş, Apache Spark ile veriler işlenmiş ve Delta Lake üzerinde Bronze, Silver ve Gold katmanlarında saklanmıştır. Makine öğrenmesi aşamasında ALS algoritması ile film puanı tahmini yapılmış, model metrikleri MLflow ile takip edilmiştir. Ayrıca Streamlit dashboard ile veri ve model sonuçları grafiksel olarak gösterilmiştir.

Anahtar Kelimeler: Büyük Veri, Apache Kafka, Apache Spark, Delta Lake, MLflow, MovieLens, ALS, Docker, Streamlit

1 Giriş

Günümüzde dijital platformlarda kullanıcı davranışlarının analiz edilmesi ve kişiselleştirilmiş öneriler üretilmesi önemli bir ihtiyaç haline gelmiştir. Film, müzik ve e-ticaret platformlarında kullanıcıların geçmiş etkileşimlerinden yararlanılarak tahmin ve öneri sistemleri geliştirilebilmektedir. Bu tür sistemlerde büyük veri teknolojileri; verinin toplanması, işlenmesi, saklanması ve modelleme süreçlerinde önemli rol oynar.

Bu proje kapsamında MovieLens 25M veri seti kullanılarak film değerlendirme ve puan tahmini yapan uçtan uca bir büyük veri pipeline sistemi geliştirilmiştir. Amaç, statik bir veri setini gerçek zamanlı veri akışı senaryosuna benzer şekilde işleyerek Kafka, Spark, Delta Lake, MLflow ve dashboard bileşenlerini tek bir mimaride birleştirmektir.

MovieLens 25M veri setindeki `ratings.csv` ve `movies.csv` dosyaları kullanılmıştır. Rating verileri Kafka producer ile Kafka topic'ine gönderilmiş, Spark Structured Streaming ile okunmuş ve Delta Lake üzerinde katmanlı veri mimarisi oluşturulmuştur.

2 Proje Mimarisi

Proje mimarisi modüler ve katmanlı olarak tasarlanmıştır. Kafka, MLflow, Spark uygulaması ve dashboard bileşenleri Docker Compose ile ayrı container'lar halinde çalıştırılmıştır. Böylece proje taşınabilir, tekrar kurulabilir ve farklı ortamlarda çalıştırılabilir hale getirilmiştir.

Genel veri akışı aşağıdaki gibidir:

MovieLens CSV → Kafka Producer → Apache Kafka → Spark Streaming → Delta Lake → ALS
Model → MLflow → Dashboard

Bu mimaride CSV formatındaki veri Python tabanlı producer ile Kafka'ya gönderilmiştir. Spark Structured Streaming Kafka topic'ini okuyarak verileri Delta Lake Bronze katmanına yazmıştır. Daha sonra Spark batch işlemleriyle Silver ve Gold katmanları oluşturulmuş, modelleme için hazır veri elde edilmiştir.

Tablo 1: Projede Kullanılan Teknolojiler

Teknoloji	Kullanım Amacı
Docker	Servisleri izole ve taşınabilir ortamda çalıştırmak.
Apache Kafka	Rating verilerini streaming veri gibi üretmek.
Apache Spark	Kafka verisini okumak, temizlemek ve dönüştürmek.
Delta Lake	Bronze, Silver ve Gold veri katmanlarını saklamak.
Spark MLlib ALS	Film puanı tahmin modeli oluşturmak.
MLflow	Model parametrelerini ve metriklerini takip etmek.
Streamlit	Dashboard ve grafiksel arayüz oluşturmak.

3 Veri İşleme Katmanları

Projede Delta Lake üzerinde Bronze, Silver ve Gold olmak üzere üç temel veri katmanı oluşturulmuştur. Bu yapı, ham verinin aşamalı olarak temizlenmesini ve modellemeye uygun hale getirilmesini sağlamıştır.

3.1 Bronze Katmanı

Bronze katmanı Kafka'dan gelen ham verinin saklandığı ilk katmandır. Kafka producer tarafından gönderilen her rating kaydı JSON formatındadır. Bu kayıtlarda kullanıcı ID'si, film ID'si, verilen puan, zaman damgası ve olay zamanı bilgisi bulunmaktadır.

```
{
  "userId": 1,
  "movieId": 296,
  "rating": 5.0,
  "timestamp": 1147880044,
  "event_time": "2006-05-17T15:34:04"
}
```

Bu veriler Spark tarafından ayrıştırılmış ve `delta/bronze/ratings` dizinine Delta formatında yazılmıştır.

3.2 Silver Katmanı

Silver katmanı, ham verinin temizlenmiş halidir. Bu aşamada eksik değerler ayıklanmış, rating değerlerinin 0.5 ile 5.0 aralığında olması kontrol edilmiş ve tekrar eden kayıtlar temizlenmiştir. Ayrıca zaman damgası tarih formatına dönüştürülerek yıl, ay ve gün bilgileri çıkarılmıştır.

Silver katmanında oluşturulan temel tablo `ratings_clean` tablosudur. Bu tablo model eğitimi için ana veri kaynağı olarak kullanılmıştır.

3.3 Gold Katmanı

Gold katmanı, analiz ve makine öğrenmesi için hazırlanmış özet tabloları içerir. Bu katmanda film bazlı toplam rating sayısı, ortalama puan, minimum ve maksimum puan gibi bilgiler hesaplanmıştır. Ayrıca kullanıcı bazlı puanlama davranışları da çıkarılmıştır.

Model eğitimi ve dashboard için `model_input`, `movie_features`, `user_features` ve `rating_predictions` tabloları oluşturulmuştur.

4 Makine Öğrenmesi Modeli

Makine öğrenmesi aşamasında Spark MLlib içerisinde yer alan ALS algoritması kullanılmıştır. ALS, kullanıcı-ürün etkileşimlerine dayalı öneri sistemlerinde kullanılan işbirlikçi filtreleme algoritmalarından biridir. Bu projede model, kullanıcıların geçmiş film puanlama davranışlarından öğrenerek belirli bir filme verilebilecek tahmini puanı hesaplamaktadır.

Model eğitimi için Silver katmanındaki temizlenmiş rating verileri kullanılmıştır. Veri eğitim ve test olarak ayrılmıştır. Kullanılan temel parametreler şunlardır:

- **rank:** Gizli faktör sayısıdır.
- **maxIter:** Maksimum iterasyon sayısıdır.
- **regParam:** Regularization parametresidir.
- **coldStartStrategy:** Tahmin üretilmeyen kayıtların düşürülmesini sağlar.

Model performansı RMSE ve MAE metrikleriyle değerlendirilmiştir. RMSE tahmin hatasının genel büyüklüğünü, MAE ise ortalama mutlak hatayı göstermektedir. Model parametreleri ve metrikler MLflow üzerine kaydedilmiştir.

5 MLflow ve Dashboard

MLflow, model deneylerinin takip edilmesi için kullanılmıştır. Her model çalıştırmasında kullanılan parametreler, eğitim-test kayıt sayıları, RMSE ve MAE değerleri MLflow üzerinde saklanmıştır. Böylece farklı model denemelerinin karşılaştırılması mümkün hale gelmiştir.

Projeye Streamlit tabanlı bir dashboard eklenmiştir. Dashboard, Delta Lake üzerindeki Gold tablolarından ve MLflow üzerinden model metriklerinden veri okuyarak görsel bir arayüz sunmaktadır. Dashboard üzerinde şu bilgiler gösterilmiştir:

- Toplam film sayısı
- Rating verilen film sayısı
- Kullanıcı sayısı
- Toplam rating kaydı sayısı
- Tahmin üretilen kayıt sayısı
- RMSE ve MAE değerleri
- Rating dağılımı
- En çok puanlanan filmler
- Ortalama puanı en yüksek filmler
- Film türlerine göre dağılım

Bu dashboard sayesinde proje çıktıları yalnızca arka planda değil, görsel olarak da takip edilebilir hale getirilmiştir.

6 Karşılaşılan Zorluklar

Proje geliştirme sürecinde bazı teknik zorluklarla karşılaşmıştır. İlk olarak Docker kurulumu sırasında Windows üzerinde WSL sürümünün güncel olmaması nedeniyle Docker Engine başlatılamamıştır. Bu sorun WSL güncellemesi ile çözülmüştür.

İkinci olarak, başlangıçta kullanılan Kafka Docker imajının ilgili sürümü bulunamadığı için container ayağa kalkmamıştır. Bu nedenle resmi `apache/kafka` imajı kullanılmış ve tek node KRaft yapılandırması yapılmıştır.

Üçüncü olarak, Dockerfile içinde kullanılan Java paketinin varsayılan Python slim imajında bulunmaması nedeniyle build işlemi hata vermiştir. Bu sorun temel imajın `python:3.11-slim-bookworm` olarak değiştirilmesiyle çözülmüştür.

Bir diğer sorun veri setinin proje klasöründe doğru seviyede bulunmamasıdır. Docker container `/app/data/raw/ml-25m/ratings.csv` yolunu beklediği için dosya doğru klasöre taşınmış ve producer başarılı şekilde çalıştırılmıştır.

Makine öğrenmesi aşamasında ise ALS sınıfında desteklenmeyen `predictionCol` parametresi kullanıldığı için hata alınmıştır. Bu parametre ALS içinden çıkarılmış ve tahmin kolonu değerlendirme aşamasında kullanılmıştır.

Dashboard aşamasında az sayıda rating kaydı kullanıldığında bazı grafiklerde yeterli veri oluşmadığı görülmüştür. Bu durum daha fazla Kafka verisi gönderilerek ve pipeline yeniden çalıştırılarak giderilebilecek bir durumdur.

7 Sonuçlar ve Değerlendirme

Bu proje sonucunda MovieLens 25M veri seti kullanılarak uçtan uca çalışan bir büyük veri pipeline yapısı geliştirilmiştir. CSV tabanlı veri Kafka producer ile streaming veri gibi üretilmiş, Spark Structured Streaming ile işlenmiş, Delta Lake üzerinde katmanlı olarak saklanmış, ALS algoritması ile film puanı tahmini yapılmış ve MLflow ile deney takibi gerçekleştirilmiştir.

Proje sonucunda elde edilen temel çıktılar Tablo 2’de gösterilmiştir.

Tablo 2: Proje Çıktıları

Çıktı	Açıklama
Kafka Streaming	Rating verileri Kafka topic’ine gönderilmiştir.
Delta Bronze	Ham Kafka verileri Delta formatında saklanmıştır.
Delta Silver	Temizlenmiş rating verisi oluşturulmuştur.
Delta Gold	Film, kullanıcı ve tahmin tabloları oluşturulmuştur.
ALS Modeli	Kullanıcı-film puan tahmini yapılmıştır.
MLflow	Model parametreleri ve metrikleri kaydedilmiştir.
Dashboard	Veri ve model sonuçları grafiklerle sunulmuştur.

Genel olarak proje, büyük veri ekosistemindeki temel teknolojilerin birlikte kullanılmasını sağlayan kapsamlı bir uygulama olmuştur. Docker ile taşınabilir çalışma ortamı kurulmuş, Kafka ile streaming mimarisi simüle edilmiş, Spark ile veri işleme yapılmış, Delta Lake ile veri saklanmış ve MLflow ile model takibi gerçekleştirilmiştir.

Gelecekte proje FastAPI tabanlı bir tahmin servisi ile geliştirilebilir. Ayrıca dashboard üzerinden kullanıcı-film seçilerek anlık tahmin yapılması, daha fazla veriyle model eğitimi yapılması ve farklı parametrelerin karşılaştırılması sağlanabilir.

8 Kaynaklar

Kaynaklar

- [1] GroupLens Research, “MovieLens 25M Dataset,” University of Minnesota.
- [2] Apache Software Foundation, “Apache Kafka Documentation.”
- [3] Apache Software Foundation, “Apache Spark Structured Streaming Documentation.”
- [4] Linux Foundation, “Delta Lake Documentation.”
- [5] MLflow, “MLflow Tracking Documentation.”
- [6] Streamlit, “Streamlit Documentation.”